

GEO：生成引擎优化

普兰贾尔·阿格瓦尔*
印度理工学院德里分校
印度新德里
pranjal2041@gmail.com

维什瓦克·穆拉哈里*
普林斯顿大学
美国普林斯顿
murahari@cs.princeton.edu

Tanmay Rajpurohit, 独立
美国西雅图
tanmay.rajpurohit@gmail.com

Ashwin Kalyan*
独立专家
美国西雅图
asaavashwin@gmail.com

卡蒂克·纳拉辛汉
普林斯顿大学
美国普林斯顿
karthikn@princeton.edu

阿米特·德什潘德
普林斯顿大学
美国普林斯顿
asd@princeton.edu

摘要

大型语言模型（LLM）的出现开创了搜索引擎的新范式，这类引擎通过生成式模型收集和总结信息来回答用户查询。这项新兴技术在生成式引擎（GE）的统一框架下得以系统化，能够生成精准且个性化的响应，迅速取代谷歌、必应等传统搜索引擎。生成式引擎通常通过整合多源信息并利用LLM进行摘要来满足查询需求。虽然这种转变显著提升了用户体验和生成式搜索引擎的流量，但给第三方利益相关者——网站和内容创作者带来了巨大挑战。由于生成式引擎具有黑箱特性且发展迅猛，内容创作者对其内容何时及如何展示几乎毫无控制权。面对生成式引擎的持续存在，我们必须确保创作者经济不受损害。为此，我们引入了生成式引擎优化（GEO），这是首个创新范式，通过灵活的黑盒优化框架帮助内容创作者提升其内容在生成式引擎响应中的可见度，该框架可优化并定义可见性指标。我们通过引入GEO基准测试，构建了一个涵盖多个领域的大规模用户查询基准，并提供相关网络资源以解答这些查询，从而实现系统的评估。通过严格评估，我们证明GEO技术可将生成引擎响应的可见度提升高达40%。此外，我们发现这些策略在不同领域的有效性存在差异，这凸显了领域特定优化方法的重要性。本研究为信息发现系统开辟了新领域，对生成引擎开发者和内容创作者都具有深远影响。

*同等出资

1可用代码和数据<https://generative-engines.com/GEO/>

允许为个人或课堂教学目的免费制作作品全部或部分内容的数字版或实体副本，但需满足以下条件：不得以盈利或商业利益为目的进行复制或分发，并且所有副本必须在首页标注版权声明及完整引用信息。对于非作者持有的作品组成部分版权，必须予以尊重。允许注明出处并附上参考文献。若需以其他方式复制、重新发布、上传至服务器或向邮件列表转发，则需事先获得特别授权和/或支付费用。相关权限申请请直接联系permissions@acm.org。

KDD '24, 2024年8月25日至29日，西班牙巴塞罗那

©2024版权所有，由版权所有者/作者（们）保留。出版许可权授予ACM。ACM ISBN 979-8-4007-0490-1/24/08
<https://doi.org/10.1145/3637528.3671900>

中国化学会概念

•计算方法→自然语言处理；机器学习；•信息系统→网络搜索和信息发现。

关键词

生成模型、搜索引擎、数据集和基准

ACM参考格式：

普兰贾尔·阿加瓦尔、维什瓦克·穆拉哈里、坦迈拉吉普罗希特、阿什温·卡利安、卡提克·纳拉辛汉与阿米特·德什潘德。2024年。《GEO：生成式引擎优化》。收录于第30届ACM SIGKDD知识发现与数据挖掘会议论文集（KDD '24），2024年8月25日至29日，西班牙巴塞罗那。ACM出版社，纽约，美国，12页。
<https://doi.org/10.1145/3637528.3671900>

1 引言

三十年前传统搜索引擎的诞生彻底革新了全球信息获取与传播方式[4]。尽管这些工具功能强大，催生了学术研究、电子商务等众多应用场景，但其功能仍局限于为用户查询提供相关网站列表。然而，大型语言模型的近期突破[5,21]为BingChat、谷歌的SGE以及困惑人工智能等更先进的系统铺平了道路，这些系统将传统搜索引擎与生成式模型相结合。我们称这类系统为生成引擎（GE），因其通过整合多源信息进行信息检索并生成多模态响应。从技术层面来看（图2），生成引擎会从数据库（如互联网）中提取相关文档，并运用大型神经网络模型生成基于原始资料的响应，确保信息来源可追溯性，并为用户提供验证信息的途径。

生成式引擎对开发者和用户的价值显而易见——用户能更快地精准地获取信息，开发者则能打造精准且个性化的回应，从而提升用户满意度和收益。然而，这种技术对第三方利益相关者——网站和内容创作者却造成不利影响。与传统搜索引擎不同，生成式引擎通过直接提供精准全面的回应，消除了用户浏览网站的必要性，可能导致网站自然流量减少并影响其可见度[16]。对于数百万依赖网络流量和可见度谋生的小企业和个人而言，生成式引

擎将严重冲击创作者经济。此外，由于生成式引擎的黑箱特性与专有属性，内容创作者在使用时面临诸多困难。




图1：我们提出的生成引擎优化（GEO）方法通过提升网站在生成引擎中的曝光度来实现价值增长。该方法的黑盒式优化框架，让原本缺乏曝光的披萨网站主也能通过优化提升搜索引擎可见性。更值得一提的是，GEO通用框架允许内容创作者自定义并优化专属曝光指标，为他们在新兴领域提供了更强的掌控力。

创作者控制和理解他们的内容是如何被摄入和描述的。

在本研究中，我们首次提出以创作者为核心的通用框架——生成引擎优化（GEO），旨在帮助内容创作者适应这一新型搜索范式。GEO作为灵活的黑盒优化框架，专为专有及闭源生成引擎设计，可提升网页内容的可见度（见图1）。该框架通过整合原始网站资源，通过调整页面布局、优化文本样式和内容结构，最终输出经过优化的版本，从而显著提升生成引擎中的内容曝光率。

此外，GEO框架引入了一个灵活的定义体系，专门用于为生成式引擎量身定制可见性指标。这是因为生成式引擎中的可见性概念比传统搜索引擎更为复杂多维（图3）。虽然在传统搜索引擎中，响应页面上的平均排名是衡量可见性的有效指标——这些引擎通常以线性列表形式展示网站——但这种评估方式并不适用于生成式引擎。生成式引擎会提供结构化丰富的响应内容，并将网站嵌入响应中作为内联引用，这些引用往往具有不同长度、位置和样式。这要求我们必须开发专为生成式引擎设计的可见性指标，通过多维度评估来衡量被引来源的可见性，例如通过客观与主观双重视角，量化引用对查询结果的相关性和影响力。

为了方便对GEO方法进行忠实和广泛的评估，我们提出了GEO-bench，这是一个由来自不同领域和来源的10000个查询组成的基准，适用于生成引擎。

通过系统性评估，我们证明所提出的生成引擎优化方法能显著提升各类查询的可见度，最高可达40%，为内容创作者提供了实用策略。研究发现，加入引用文献、相关来源的引文及统计数据等元素，可大幅提升内容源的可见度，在多种查询场景中增幅超过40%。我们还在真实应用场景Perplexity.ai上验证了该优化方法的有效性，可见度提升幅度最高达37%。

总之，我们的贡献有三个方面：

- (1)我们提出生成式引擎优化（Generative Engine Optimization），这是首个专为网站所有者设计的通用优化框架，旨在帮助他们针对生成式引擎优化网站。通过在多种查询、域名和真实黑盒生成式引擎上应用该技术，可使网站可见度提升高达40%。
- (2)我们的框架提出了一套专门为生成引擎设计的可见性指标，使内容创建者能够通过定制的可见性指标灵活优化他们的内容。
- (3)为了促进对生成引擎中GEO方法的忠实评估，我们提出了第一个大规模基准测试，包括来自广泛领域的多样化搜索查询和专门为生成引擎定制的数据集。




图2: 生成式引擎概述。生成式引擎主要由一组生成模型和一个检索相关文档的搜索引擎组成。生成式引擎以用户查询为输入, 通过一系列步骤生成最终响应, 该响应基于检索到的源内容, 并附带内嵌属性。

2. 配方与方法

2.1 生成引擎的构建

尽管已有众多生成式引擎部署给数百万用户, 但目前仍缺乏统一标准框架。我们提出了一种可兼容多种模块化组件的设计方案。该方案包含多个后端生成模型和用于源检索的搜索引擎。生成式引擎 (GE) 接收用户查询 q 并返回自然语言响应 r , 其中 P_u 代表个性化用户信息。该引擎可表示为函数形式:

$$f_{GE} := (q_u, P_u) \rightarrow r(1)$$

生成式引擎包含两个关键组件: a.) 一组生成模型 $G = \{G_1, G_2 \dots G_n\}$, 每个模型承担特定功能 (如查询重构或摘要生成); b.) 搜索引擎 SE , 根据输入查询 q 返回资源集合 $S = \{s_1, s_2 \dots s_m\}$ 。图2展示了典型工作流程示意图, 该设计在撰写本文时与必应聊天 (BingChat) 的架构高度相似。该流程将输入查询拆解为多个更易被搜索引擎处理的子查询。当输入查询 q 时, 重构生成模型 $G_1 = G_{qr}$ 会生成子查询集 $Q_1 = \{q_1, q_2, \dots, q_n\}$, 随后传递给搜索引擎 SE 获取排序资源集合 $S = \{s_1, s_2 \dots s_m\}$ 。这些资源集合再输入摘要生成模型 $G_2 = G_{sum}$, 为每个资源生成摘要 $sum_1, sum_2, \dots, sum_m$, 最终形成摘要集合 $Sum = \{sum_1, sum_2, \dots, sum_m\}$ 。摘要集合随后进入响应生成模型 $G_3 = G_{resp}$, 基于资源 S 生成累积响应 r 。本研究聚焦单轮对话生成引擎, 但该框架可扩展至多轮对话生成引擎 (详见附录A)。

响应 r 通常以结构化文本形式呈现, 并嵌入引用信息。鉴于语言模型容易产生信息幻觉[10], 引用信息尤为重要。具体而言, 考虑由句子 $\{l_1, l_2 \dots l_o\}$ 组成的响应 r , 每个句子都可能附带一组引用文献 $c_i \subset S$ 。理想的生成式引擎应确保响应中的所有陈述都获得相关引用支持 (高引用召回率), 且所有引用都能准确支撑其对应的陈述内容。

与 (高引用精度) [14]相关联。我们建议读者参见图3以获取一个典型的生成引擎响应。

2.2 生成引擎优化

搜索引擎的出现催生了搜索引擎优化 (SEO) 这一技术, 其核心在于帮助网站创建者通过优化内容来提升搜索引擎排名。更高的排名意味着更高的曝光度和网站流量。然而传统SEO方法并不适用于生成式引擎。这是因为与传统搜索引擎不同, 生成式引擎中的语言模型不仅限于关键词匹配, 通过使用语言模型处理源文档并生成响应结果, 能够更精准地理解文本内容和用户查询。随着生成式引擎迅速成为主流信息传递方式, 而SEO又无法直接套用, 我们需要开发新的技术手段。为此, 我们提出了生成式引擎优化这一新范式, 即内容创作者致力于在生成式引擎响应中提升自身可见度 (或称曝光量)。我们定义网站在被引用响应 r 中的可见度 (亦称引用量) c_i 为函数 $Imp(c_i, r)$, 这是网站创建者希望最大化的目标。从生成式引擎的角度看, 其目标是最大化与用户查询最相关的引用可见度, 即最大化 $\sum_i (Imp(c_i, r), Rel(c_i, q, r))$, 其中 $Rel(c_i, q, r)$ 衡量引用 c_i 在响应 r 上下文中与查询 q 的相关性, 而 r 则由生成式引擎的具体算法设计决定, 对终端用户而言是一个黑箱函数。此外, Imp 和 Rel 这两个函数都是主观的, 对于生成引擎来说还没有明确定义, 我们将在下面定义它们。

2.2.1 生成式搜索引擎的展示效果评估。在搜索引擎优化 (SEO) 中, 网站的展示量 (或可见度) 主要取决于其在各类搜索查询中的平均排名。但生成式引擎的输出特性要求采用不同的展示指标。与传统搜索引擎不同, 生成式引擎会将多源信息整合到单一响应中。引用内容的长度、独特性及呈现方式等要素, 才是决定引用真实可见度的关键因素。如图3所示, 虽然传统搜索引擎的响应页面简单排名能有效衡量展示量和可见度, 但对于生成式引擎的响应而言, 这类指标并不适用。

针对这一挑战, 我们提出了一套印象度评估指标体系, 其设计遵循三大核心原则: 1) 指标需与创作者产生共鸣; 2) 具备可解释性; 3) 让各类内容创作者都能轻松理解。首项指标 “word计数” (Word Count) 定义为: 引用相关句子的标准化词数统计。具体数学表达式如下:

$$Imp_{wc}(c_i, r) = \frac{\sum_{s \in S_{c_i}} |s|}{\sum_{s \in S_r} |s|} \quad (2)$$

其中, S_{c_i} 表示引用 c_i 的句子集合, S_r 表示响应中的句子集合, $|s|$ 表示句子 s 的单词数。当某句被多个来源引用时, 我们会将词数平均分配给所有引用源。直观来说, 词数越多意味着该来源在答案中起着更重要的作用, 因此用户能获得更多接触该来源的机会。

排名查询：纽约有什么好去处？

1	1. 纽约中央公园 逃离城市的喧嚣，悠闲地漫步在市中心 的中央公园。
2	2. 自由女神像 去参观自由女神像，它不仅是一座纪念碑 ，更是希望和自由的象征。
3	3. 纽约风味披萨 品尝著名的纽约式披萨，这是一种无与伦 比的美食体验。

是否由创作者知道
如何衡量可见性？ ✓✓✓
如何提高可见性？ ✓✓
我的内容是如何被描述的？ ✓✓✓

问题：纽约有什么好玩？排名
问题：纽约有什么好玩的？排名

品味标志性的纽约风格 披萨店，一家古雅的小餐馆 点缀中央公园的周边，结合两种 美食 还有美丽的风景[1,3]。惊叹自由女神 像的历史[2]，这个大熔炉的景象甚至 反映在本地人和游客喜爱的各种 披萨配料上 alike[2,3]。当白昼渐趋黄昏，漫步中 央公园，就像享用完一顿美味佳 肴后那种令人平静的感觉。	？ ？ ？
--	-------------

搜索引擎生成引擎

搜索引擎生成引擎

图3：传统搜索引擎的排名与可见性指标相对简单，它们以逐字内容形式按序列出网站来源。而生成式引擎则能生成结构化丰富的响应，通常将引用内容嵌入单个区块并相互交织。这使得排名和可见性具有复杂多维的特性。此外，与搜索引擎不同，虽然在提升可见性方面已有大量研究，但如何优化生成式引擎的响应可见性仍不明确。为解决这些挑战，我们的黑盒优化框架提出了一系列精心设计的展示效果指标，创作者可据此评估并优化网站表现，还能自主定义展示效果指标。

然而，由于“Word计数”不受引用排名的影响（例如是否排名第一），我们提出了一种位置调整计数方法，通过引用位置的指数衰减函数来降低权重：

$$Imp_{pwc}(c_i, r) = \frac{\sum_{s \in S_{c_i}} |s| \cdot e^{-\frac{pos(s)}{|S|}}}{\sum_{s \in S_r} |s|} \quad (3)$$

直观来看，响应中排名靠前的句子更容易被用户阅读，而Imp_{pwc}定义中的指数项会为这类引用赋予更高权重。因此，尽管字数较少，位于搜索结果顶部的网站可能比中段或末尾的网站获得更高的曝光量。此外，选择指数衰减函数的动机源于多项研究显示，点击率与搜索引擎排名呈幂律关系[7,8]。虽然上述曝光度指标客观且有理论依据，但它们忽略了引用对用户注意力影响的主观层面。为此，我们提出“主观印象”指标，该指标综合考量引用内容与用户查询的相关性、引用影响力、引用内容的独特性、主观立场、主观数量、点击概率以及呈现内容的多样性。我们采用当前评估大语言模型的最先进工具G-Eval [15]来测量这些子指标。

2.2.2网站生成式引擎优化方法。为提升网站曝光度指标，内容创作者需要对网站内容进行调整。我们提出了一系列与生成式引擎无关的策略，称为生成式引擎优化方法（GEO）。从数学角度而言，每个GEO方法都是一个函数 $f: W \rightarrow W'$ ，其中 W 表示初始网页内容，而 W' 是

应用GEO方法后的修改内容。这些调整既可进行简单的风格优化，也能以结构化形式融入新内容。一个设计精良的GEO方法相当于黑盒优化技术——即便不了解生成引擎的具体算法架构，也能提升网站可见度，并能独立于具体查询条件对网站文本进行修改。

在实验中，我们运用生成引擎优化方法对网站内容进行处理，通过大型语言模型在系统提示下执行特定的风格调整和内容修改。具体而言，基于GEO方法定义的一系列目标特征，源内容将被相应地进行优化调整。我们提出了并评估了多种此类方法：

- 权威性优化：通过调整内容风格提升说服力与权威性；
 - 数据强化：尽可能用量化数据替代定性分析；
 - 关键词堆砌：按照经典SEO优化原则，增加与关键词相关的搜索词；
 - 引用规范：规范引用来源并添加可信渠道的权威引文；
 - 简洁语言：优化网站文字表达；
 - 流畅度优化：提升网页文本的流畅性；
 - 独特词汇：在可能情况下添加专业术语；
 - 技术术语：根据需要添加专业术语。
- 这些方法涵盖网站运营者可快速实施的通用策略，适用于各类网站内容。除第3、4、5项外，其余方法通过增强现有内容的呈现效果来提升说服力或搜索引擎吸引力，无需额外添加内容。另一方面，第3、4、5项可能
- 权威性优化：通过调整内容风格提升说服力与权威性；
 - 数据化处理：尽可能用量化数据替代定性分析；
 - 关键词堆砌：按照经典SEO优化原则，增加与关键词相关的搜索词；
 - 引用规范：规范引用来源并添加可信渠道的权威引文；
 - 简洁语言：优化网站文字表达，同时
 - 流畅度优化：提升网页文本的流畅性；
 - 独特词汇：在可能情况下添加专业术语；
 - 技术术语：根据

KDD '24,2024年8月25日至29日，西班牙巴塞罗那。普兰贾尔·阿加瓦尔等人。
年8月25日至29日，西班牙巴塞罗那。普兰贾尔·阿加瓦尔等人。

KDD '24,2024

需要添加专业术语。这些方法涵盖多种通用策略，网站运营者可快速
实施且无需额外内容。除第3、4、5项外，其余方法通过增强现有内容
的呈现效果来提升说服力或吸引搜索引擎，无需新增内容。另一方面，
第3、4、5项可能

需要补充某种形式的附加内容。为了分析我们方法的性能增益，针对每个输入用户查询，我们随机选择一个源网站进行优化，并在同一源网站上分别应用每种GEO方法。关于GEO方法的更多细节，请参阅附录B.4。

3实验设置

3.1评估生成引擎

与先前研究[14]一致，我们采用两步式架构设计生成式引擎。第一步获取输入查询的相关源信息，第二步由语言模型（LLM）基于这些源信息生成响应。与前人工作类似，我们不使用摘要功能，而是为每个源提供完整响应。考虑到上下文长度限制及transformer模型的二次方级扩展成本，每次查询仅从谷歌搜索引擎获取前五名相关源。该架构严格遵循先前研究的工作流程，并与you.com、perplexity.ai等商用生成式引擎采用的设计理念高度一致。随后使用与先前研究[14]相同的提示词，通过gpt3.5-turbo模型[20]生成答案。为降低统计偏差，我们在温度参数设置为0.7时采样了五个不同响应。

在第C.1节中，我们还在Perplexity.ai上评估了相同的生成引擎优化方法，这是一个商用部署的生成引擎，突出了我们提出的生成引擎优化方法的普适性。

3.2基准：GEO-bench

由于目前尚未有公开数据集包含与生成引擎相关的查询，我们特别策划了GEO基准测试。该基准由来自多个来源的1万条查询组成，经过重新设计适配生成引擎使用，并辅以人工合成的查询样本。测试集涵盖九个不同来源的查询内容，每个来源均根据目标领域、难度等级、查询意图等维度进行细分类。

数据集：1. MS Macro，2. ORCAS-1,3. 自然问题：[1,6,13]这些数据集包含来自必应和谷歌搜索引擎的真实匿名用户查询。这三组数据共同构成了搜索引擎相关研究中常用的基准数据集。然而，生成式引擎将面临更具挑战性和针对性的查询任务，其目标是从多个来源综合聚合答案而非单纯检索。为此，我们重新利用了其他几个公开可用的数据集：4. AllSouls：该数据集包含牛津大学万灵学院的论文题目。这些题目要求生成式引擎通过恰当推理从多源信息中整合内容。5. LIMA：[25]包含需要生成式引擎不仅整合信息还需进行适当推理来回答问题的难题（例如创作短诗、编写python代码）。

6. 达芬奇辩论[14]包含为测试生成引擎而设计的辩论问题。7. Perplexity.ai Discover2：这些查询源自Perplexity.ai的Discover部分，该部分

平台上的最新热门问题列表。8. ELI-53：该数据集包含来自ELI5子版块的问题，用户在此提出复杂问题，并期望获得简单、通俗易懂的语言回答。

9. GPT-4生成的查询：为了补充查询分布的多样性，我们提示GPT-4[21]根据查询意图（例如导航、事务性）以及生成响应的难度和范围（例如开放式、基于事实），生成来自不同领域（例如科学、历史）的查询。

我们的基准测试集包含1万条查询语句，分别划分为训练集、验证集和测试集各8000条、1000条和1000条。为保持真实查询分布特征，基准集包含80%的信息类查询，交易类和导航类各占10%。每个查询语句都附加了谷歌搜索引擎前五条搜索结果的清理文本内容。

标签。优化网站内容通常需要根据任务领域进行针对性调整。此外，使用生成式引擎优化的用户可能需要针对特定查询子集确定合适方法，这需要综合考虑域名、用户意图和查询性质等多个因素。为此，我们为每个查询添加七个不同类别的标签。在标注过程中，我们采用GPT-4模型，并通过测试集验证其高召回率和高精确度。

总体而言，GEO基准测试集包含来自艺术、健康、游戏等25个不同领域的查询任务，其难度涵盖从简单到多维度的多种类型，包含信息类、事务类等9种不同类型的查询，并设有7个分类体系。得益于其精心设计的高度多样性、庞大的规模以及贴近现实的特性，GEO基准测试集成为评估生成式引擎的综合性基准平台，可作为当前及未来研究中各类应用场景下的标准测试基座。关于GEO基准测试集的更多细节，请参阅附录B.2。

3.3 GEO方法

我们评估了第2.2.2节所述的9种不同的GEO方法，并将其与基准测试进行对比——该基准测试衡量未经修改的网站来源的展示效果指标。我们在完整的GEO基准测试数据集上对这些方法进行了评估。此外，为减少结果差异，我们使用五个不同的随机种子进行实验，并报告平均值。

3.4评估指标

我们采用第2.2.1节定义的影响力评估指标。具体而言，我们使用两种影响力指标：1.位置调整Word计数，该指标综合了词频和位置统计。为分析各组成部分的影响，我们还分别报告了两个子指标的得分。2.主观影响力，这是一个涵盖七个不同维度的主观评估指标：1) 引用句子与用户查询的相关性；2) 引用影响力，评估生成响应对引用内容的依赖程度；3) 引用材料的独特性，衡量引用内容呈现的原创性；4) 主观位置，从用户视角评估来源内容的突出程度；5) 主观数量，统计呈现内容的总量。

²<https://www.perplexity.ai/discover>

GEO: 生成引擎优化KDD '24,2024年8月25日至29日, 西班牙巴塞罗那
年8月25日至29日, 西班牙巴塞罗那
3https://huggingface.co/datasets/eli5_category

GEO: 生成引擎优化KDD '24,2024

方法	位置调整Word计数主观印象						位置调整Word计数主观印象								
	Word位置总体相对影响独特分区后续位置数量平均值			Word位置总体相对影响独特分区跟踪位置数量平均值			Word位置总体相对影响独特分区跟踪位置数量平均值			Word位置总体相对影响独特分区跟踪位置数量平均值					
	没有生成引擎优化的性能														
无优化	19.5	19.3	19.3	19.3	19.3	19.3	19.3	19.3	19.3	19.3	19.3	19.3	19.3	19.3	19.3
非性能生成式引擎优化方法															
关键词堆砌					17.8	17.7	17.7	19.8	19.1	20.5	20.4	20.3	20.5	20.4	20.2
独特词汇					20.7	20.5	20.5	20.5	20.1	19.9	20.4	20.2	20.7	20.2	20.4
高性能生成引擎优化方法															
易于理解					22.2	22.4	22.0	20.2	21.0	20.0	20.1	20.1	20.9	19.9	20.5
权威性					21.8	21.3	21.3	22.3	22.1	22.4	23.1	22.2	23.1	22.7	22.9
技术术语					23.1	22.7	22.7	20.9	21.7	20.5	21.2	20.8	21.9	20.8	21.4
流利度优化					25.1	24.6	24.7	21.1	22.9	20.4	21.6	21.0	22.4	21.1	21.9
引证来源					24.9	24.5	24.6	21.4	22.5	21.0	21.6	21.2	22.2	20.7	21.9
报价增加					27.8	27.3	27.2	23.8	25.4	23.9	24.4	22.9	24.9	23.2	24.7
统计学补充					25.9	25.4	25.2	22.5	24.5	23.0	23.3	21.6	24.2	23.0	23.7

表1: GEO方法在GEO基准测试中的绝对印象度指标。性能评估基于两项核心指标及其子指标。相较于传统SEO常用的关键词堆砌等基础方法，我们的创新方案在统计学加权与引文加权等指标上展现出显著提升。其中最佳方案在位置调整Word计数和主观印象度两项指标上分别实现41%和28%的突破性增长。为确保可读性，我们采用位置调整Word计数对主观印象度进行标准化处理，使其基准值保持高度一致。

用户对引用内容的感知、6) 用户点击引用的可能性，以及7) 呈现材料的多样性。这些子指标评估了内容创作者可以有效优化的一个或多个方面。每个子指标均采用GPT-3.5进行评估，其方法论类似于G-Eval [15]中描述的方式。在G-Eval中，语言模型会获得基于表单的评估模板，以及包含引用内容的GE生成响应。模型会对每个引用输出一个分数（通过多次采样计算得出）。但由于G-Eval评分校准度不足，我们将其标准化为与位置调整后的Word计数具有相同均值和方差，以确保公平且有意义的比较。附录B.3中提供了具体使用的评估模板。

此外，所有展示指标均通过乘以一个常数因子进行标准化处理，使得响应中所有引用的展示次数总和等于1。在分析过程中，我们通过计算展示量的相对改进值来比较不同方法。对于初始生成的响应 r （来自源 $s_i \in \{s_1, \dots, s_m\}$ ）及其修改后的响应 r' ，每个源 s_i 的展示量相对改进值可按以下公式计算：

$$\text{改进值} = \text{Imp } s_i(r) \times \frac{\text{Imp } s_i(r') - \text{Imp } s_i}{100} \times 100 \quad (4)$$

$$\text{改进值} = \text{Imp } s_i(r) \times 100 \quad (4)$$

修改后的响应 r' 是通过将正在评估的GEO方法应用于其中一个源 s_i 而产生的。用于优化的源 s_i 是随机选择的，但在特定查询中，该源在所有GEO方法中保持不变。

4结果

我们评估了多种旨在优化网站内容以提升在生成式搜索引擎（GE）响应中可见度的生成引擎优化方法，并与未进行优化的基准组进行对比。评估采用GEO-bench测试平台，该平台整合了来自多个领域和场景的多样化用户查询数据。性能评估采用两个指标：位置调整Word计数和主观印象评分。前者综合考量词汇量及GE响应中的引用位置，后者则通过多维度主观因素计算得出整体印象评分。

表1详细列出了不同方法在多项指标上的绝对印象度评估结果。研究数据显示，我们的GEO方法在GEO基准测试中各项指标均持续超越基线模型，展现出对多样化查询的稳健性，即便面对查询差异也能实现显著提升。具体而言，表现最佳的三种方法——引用来源统计、引文添加和主观印象统计——在位置调整Word计数指标上实现了30-40%的相对提升，在主观印象指标上则达到15-30%的提升。这些方法通过在网站内容中引入相关统计数据（统计添加）、整合可信引文（引文添加）以及包含可靠来源的引用（引用来源统计），仅需微小改动即可显著提升GE搜索结果中的可见度，从而增强内容的可信度与丰富性。

有趣的是，诸如提高源文本流畅性和可读性（流畅性优化和易于理解）等风格变化，也带来了15-30%的显著可见度提升。这表明生成引擎不仅重视内容，还重视信息呈现方式。

方法	可见性相对改善 (%)				
	等级1、	等级2、	等级3、	等级4、	等级5
权威性	-6.0	4.1	-0.6	12.6	6.1
流利度选项。	-2.0	5.2	3.6	-4.4	2.2
引证来源	-30.3	2.5	20.4	15.5	115.1
报价增加	-22.9	-7.0	3.5	25.1	99.7
统计学补充	-20.6	-3.9	8.1	10.0	97.9

表2：不同搜索引擎排名的网站通过GEO方法获得的可见性变化。GEO对排名较低的网站特别有帮助。

此外，由于生成式模型通常被设计为遵循指令，人们本以为网站内容若采用更具说服力和权威性的语气会提升可见度。然而我们并未发现显著改善，这表明生成引擎对这类调整已具备较强适应性。这凸显出网站运营者需要着力优化内容呈现方式与可信度。

最后，我们评估了关键词堆砌策略——即在网站内容中添加更多相关关键词。尽管这种做法在搜索引擎优化领域应用广泛，但我们发现它对生成式搜索引擎的响应效果几乎毫无提升。这凸显出网站运营者需要重新思考针对生成式搜索引擎的优化策略，因为在传统搜索引擎中有效的技术手段，在这种新型模式下可能难以奏效。

5分析

5.1 针对特定领域的生成引擎优化

在第四节中，我们展示了GEO基准测试中所有指标的改进成果。然而在实际SEO场景中，通常需要进行领域特定优化。基于此考量，并考虑到我们在GEO基准测试中为每个查询都设置了分类标准，我们将深入分析各类GEO方法在不同分类下的具体表现。

表3详细列出了我们的GEO方法在哪些类别中表现最为出色。通过深入分析这些结果，我们发现几个引人注目的现象。例如，在辩论类问题和“历史”领域相关查询中，权威性显著提升了性能表现。这与我们的直觉不谋而合——毕竟更具说服力的写作形式，在辩论场景中往往更具价值。

同样，通过Cite Sources添加引文对事实性问题尤为有效，这可能是引文为所呈现的事实提供了验证来源，从而提升了回答的可信度。不同GEO方法在不同领域的有效性存在差异。例如，如表3第5行所示，通过统计信息添加功能在网站内容中加入相关统计数据后，“法律与政府”等领域以及“观点”类问题类型显著受益。这表明数据驱动的证据能增强网站在特定情境下的可见度。引文添加法在“人物与社会”、“解释”和“历史”领域效果最佳，这可能是因为这些领域通常

方法	最常用标签		
	第1名	排名2	排名3
权威性	辩论	历史	科学
流利度选项。	业务	科学	健康
引证来源	声明	事实	法律和政府。
报价增加	人民与社会	说明	历史
统计学补充	法律和政府。	辩论	意见

表3：各GEO方法的顶级表现类别。网站所有者可以根据其目标领域选择相关的GEO策略。




图4：GEO策略组合的相对改进效果。结合使用流畅度优化和统计加法可获得最佳性能。最右侧一列显示，将流畅度优化与其他策略结合使用效果最佳。

涉及个人经历或历史事件时，直接引用能为内容增添真实感和深度。总体而言，我们的分析表明，网站运营者应致力于针对特定领域进行精准优化调整，以提升网站的可见度。

5.2 多站点优化

在生成式引擎不断发展的领域中，GEO方法预计将被广泛采用，最终形成所有源内容均通过GEO进行优化的场景。为理解这一影响，我们通过同步优化所有源内容对GEO方法进行了评估，结果如表2所示。关键发现是GEO对不同网站的排名影响存在差异——通常难以获得曝光的低排名网站，反而能从GEO中获益更多。这是因为传统搜索引擎依赖多种因素（如反向链接数量和域名存在度），而这些指标对小型创作者而言实现难度较大。然而，由于生成式引擎利用...

方法	地理优化	相对改善
引证来源	问：瑞士巧克力的秘诀是什么？	
	瑞士人的人均年消费量平均在11到12公斤之间，是世界上最大的巧克力爱好者之一（根据国际巧克力公司的一项调查）	132.4%
	消费研究组[1]	
统计学补充	问：机器人应该取代人类吗？	
	来源：不是在这里，也不是现在——直到最近。最大的不同在于，机器人来不是为了破坏我们的生活，而是为了扰乱我们的工作，	65.5%
	在过去十年里，机器人的参与度惊人地增长了70%。	
权威性	问：杰克逊维尔美洲虎队曾经进入过超级碗吗？	
	来源：需要注意的是，美洲虎队从未在超级碗中亮相。然而，他们已经取得了令人印象深刻的成就，赢得了4次分区冠军。	89.1%
	这是他们的名字，是他们能力和决心的证明。	

表4: GEO方法优化源网站的代表性案例。新增内容用绿色标注，删除内容用红色标注。在不添加任何实质性新信息的情况下，GEO方法显著提升了源内容的可见度。

基于网站内容生成的模型中，诸如外链建设等因素不应让小型创作者处于劣势。表2显示的可见性相对提升数据就印证了这一点。例如，引用来源方法使搜索引擎结果页排名第五的网站可见性是升了115.1%，而平均而言，排名第一的网站可见性却下降了30.3%。

这一发现凸显了GEO算法在数字空间民主化方面的潜力。许多排名靠后的网站由小型内容创作者或独立企业运营，这些企业传统上难以在搜索引擎结果首页与大型企业竞争。生成式引擎的出现对这些小型实体而言看似不利，但应用GEO方法却为内容创作者提供了提升在生成式引擎搜索结果中可见度的机遇。通过运用GEO优化内容，他们能触达更广泛的受众群体，实现公平竞争环境，从而更有效地与大型企业展开较量。

5.3 GEO战略的组合

尽管各类地理优化策略在多个领域都展现出显著提升，但实际应用中网站运营者通常需要综合运用多种策略。为研究组合使用地理优化策略带来的性能提升效果，我们选取了表现最佳的四种策略——引用源优化、流畅度优化、统计信息增强和引文添加——的所有组合方案进行分析。图4展示了不同地理优化策略组合对位置调整Word计数可见性指标的相对提升热力图。分析表明，生成引擎优化方法的组合能有效提升性能，其中最佳组合（流畅度优化与统计信息增强）的表现比单一策略高出5.5%以上4。此外，引用源优化在使用时也能显著提升整体性能。

4由于成本限制，分析是在测试集的200个样本子集中进行的，因此这里呈现的数字与表1中的数字不同。

尽管单独使用时效果相对较低（比报价添加法低8%），但与其他方法结合使用时（平均31.4%）仍表现出色。研究结果强调了联合使用GEO方法的重要性，因为这些方法更符合内容创作者在现实场景中的实际应用需求。

5.4定性分析

我们在表4中对GEO方法进行了定性分析，其中包含多个典型案例，展示了如何通过最小改动提升内容来源的可见度。每种方法都通过合理增删文本来优化信息源。第一个案例表明，仅需添加陈述的来源信息就能显著提升最终答案的可见度，这对内容创作者来说几乎无需额外努力。第二个案例说明，在可能的情况下添加相关统计数据，能有效增强生成引擎最终响应中的来源可见度。最后第三个案例则提示，单纯强调文本中的关键部分并采用更具说服力的写作风格，同样能提升内容的可见度。

6《荒野中的GOE》：部署生成引擎的实验

方法	位置调整Word计数主观印象	
未优化	24.1	24.7
关键词堆砌	21.9	28.1
报价增加	29.1	32.1
统计学补充	26.2	33.9

表5: GEO方法在GEO基准测试中使用Perplexity.ai作为生成引擎的绝对印象指标。尽管关键词堆砌等SEO方法表现不佳，但本文提出的GEO方法对多种生成引擎具有良好的泛化能力，显著提升了内容可见度。

KDD '24, 2024年8月25日至29日, 西班牙巴塞罗那。普兰贾尔·阿加瓦尔等人。
年8月25日至29日, 西班牙巴塞罗那。普兰贾尔·阿加瓦尔等人。

KDD '24, 2024

为了验证我们提出的生成引擎优化方法的有效性, 我们在 Perplexity.ai 上进行了评估。Perplexity.ai 是一个拥有庞大用户群体的真实部署生成引擎。结果如下:

如表5所示，与我们的生成引擎类似，引用添加方法在位置调整Word计数指标上表现最佳，较基线提升了22%。在生成引擎中表现优异的方法（如Cite Sources、Statistics Addition）在这两项指标上分别提升了9%和37%。我们观察到传统SEO方法（如关键词堆砌）效果不佳，其表现比基线差10%，这一现象进一步得到印证。这些结果具有三大重要意义：1）强调了开发不同生成引擎优化方法对内容创作者的重要性；2）突显了我们提出的GEO方法在不同生成引擎上的普适性；3）证明内容创作者可直接采用我们提出的易于实施的GEO方法，从而产生显著的实际效果。更多细节请参阅附录C.1。

7相关工作

基于证据的答案生成：先前研究采用多种技术手段生成源支持的答案。中野等人[19]训练GPT-3在网页环境中导航以生成源支持答案。类似地，其他方法[17,23,24]通过搜索引擎抓取资源来生成答案。我们的研究整合了这些方法，并为未来改进系统提供统一基准。在近期工作草案中，库马尔和拉卡拉朱[11]展示了通过战略性文本序列操控大模型推荐，可提升生成式引擎中的产品可见度。虽然他们的方法侧重于通过对抗性文本增强产品曝光度，而我们的方法则引入非对抗性策略，旨在优化网站内容以提升生成式引擎搜索结果中的可见度。

检索增强型语言模型：近期多项研究通过从知识库中提取相关资源来解决语言模型记忆有限的问题[3,9,18]。然而，生成引擎需要在回答过程中持续生成答案并提供归因信息。此外，生成引擎的输入输出不限于单一文本模态。更值得一提的是，其框架不仅支持资源提取，还包含查询重构、资源选择以及决策执行时机与方式等多项功能。

搜索引擎优化（SEO）：在过去的近25年里，大量研究致力于优化网页内容以适应搜索引擎[2,12,22]。这些方法可分为站内SEO和站外SEO两大类：前者通过提升内容质量与用户体验来增强网站权重，后者则通过链接建设来增强网站权威性。相比之下，生成式搜索引擎优化（GEO）需要应对更复杂的多模态交互环境。由于GEO针对的优化模型不局限于简单的关键词匹配，传统SEO策略无法适配生成式引擎的特性，这凸显了GEO技术的独特价值。

8结论

在本研究中，我们开发了一种结合生成模型的搜索引擎，将其命名为生成引擎。我们提出了生成引擎优化（GEO）方法，旨在为内容创作者提供支持。

为优化生成式引擎的内容质量，我们定义了生成引擎的影响力评估指标，并提出并发布了GEO基准测试：该基准测试涵盖来自多个领域和场景的多样化用户查询，以及解答这些查询所需的相关资源。我们提出了多种优化生成式引擎内容的方法，并证明这些方法可使生成式引擎响应中的资源可见度提升高达40%。其他发现表明，包含引用文献、相关来源的引文及统计数据能显著提高资源可见度。此外，我们发现GEO方法的有效性取决于查询领域，并且结合多种GEO策略具有潜力。我们在拥有数百万活跃用户的商用生成式引擎上展示了有希望的结果，彰显了本研究的实际应用价值。总之，我们的工作首次系统化了重要且及时的GEO范式，通过发布算法和基础设施（基准测试、数据集及评估指标），推动社区在生成式引擎领域的快速发展。这标志着理解生成式引擎对数字空间影响的第一步，同时也揭示了GEO在这一新型搜索引擎范式中的作用。

9限制

尽管我们已在两个生成引擎（包括一个公开可用的）上严格测试了所提出的方法，但随着生成引擎的演进，这些方法可能需要随时间调整——这与搜索引擎优化（SEO）的发展轨迹如出一辙。此外，虽然我们努力确保GEO基准中的查询语句尽可能贴近真实场景，但查询内容本身会随时间推移发生变化，因此需要持续更新。再者，由于搜索引擎算法具有黑箱特性，我们未评估GEO方法对搜索排名的影响。但需指出的是，GEO方法对文本内容的调整具有针对性，与SEO方法存在相似性，但不会影响域名、反向链接等元数据，因此对搜索引擎排名的影响较小。随着语言模型中更大上下文长度变得经济实惠，未来生成模型有望整合更多数据源，从而降低搜索排名的影响。最后需要说明的是，虽然我们提出的GEO基准中的每个查询都经过标注和人工审核，但仍可能存在因主观判断或标注错误导致的差异。

10致谢

本材料基于美国国家科学基金会资助的研究工作，资助编号为2107048。本材料中表达的任何观点、发现、结论或建议均属于作者个人，不一定反映美国国家科学基金会的观点。

参考文献

- [1]达里亚·亚历山大、沃伊切赫·库萨与阿扬·P·德弗里斯。2022年。ORCAS-I：基于弱监督的意图标注查询。第45届国际ACM SIGIR信息检索研究与发展会议论文集（2022）。<https://api.semanticscholar.org/CorpusID: 248495926>
- [2]普拉山特·安卡尔科蒂。2017年。《搜索引擎优化工具与技术综述》。《帝国跨学科研究期刊》第3卷（2017）。<https://api.semanticscholar.org/CorpusID: 116487363>
- [3]阿萨伊·阿卡里、余新岩·维斯蒂、笠井·荣子和哈吉希尔·汉纳。2021年。一种多语言跨语言问题回答模型

- 密集通道检索。载于《神经信息处理系统》。https://api.semanticscholar.org/CorpusID: 236428949
- [4]谢尔盖·布林和劳伦斯·佩奇。1998年。《大型超文本网络搜索引擎的结构分析》。《计算机网络》第30卷(1998年), 第107-117页。https://api.semanticscholar.org/CorpusID: 7587743
- [5]汤姆·布朗、本杰明·曼、尼克·莱德、梅兰妮·苏比亚、贾里德·D·卡普兰、普拉富拉·达里瓦尔、阿文德·尼拉坎坦、普拉纳夫·夏姆、吉里什·萨斯特里、阿曼达·阿斯科尔、桑迪尼·阿加瓦尔、阿里尔·赫伯特·沃斯、格雷琴·克鲁格、汤姆·亨里根、瑞温·柴尔德、阿迪提亚·拉梅什、丹尼尔·齐格勒、杰弗里·吴、克莱门斯·温特、克里斯·赫塞、马克·陈、埃里克·西格勒、马泰乌什·利特温、斯科特·格雷、本杰明·切斯、杰克·克拉克、克里斯托弗·伯纳、萨姆·坎德利什、亚历克·拉德福德、伊利亚·苏茨克韦尔和达里奥·阿莫代。2020年。《语言模型是少样本学习者》。收录于H·拉谢罗、M·兰扎托、R·哈塞尔、M·F·巴尔坎和H·林主编的《神经信息处理系统进展》第33卷(柯伦联合出版社, 1877-1901年)。https://proceedings.neurips.cc/paper_files/paper/2020/file/1457c0d6bfc4967418bf8ac142f64a-Paper.pdf
- [6]尼克·克拉斯韦尔、巴斯卡尔·米特拉、埃明·伊尔马兹、丹尼尔·费尔南多·坎波斯和林吉米。2021年。MS MARCO: 大规模数据环境下排名模型的基准测试。第44届国际ACM SIGIR信息检索研究与发展会议论文集(2021)。https://api.semanticscholar.org/CorpusID: 234336491
- [7] Brian Dean. 2023 我们分析了400万条谷歌搜索结果。关于自然点击率的发现。https://backlinko.com/google-ctr-stats访问日期: 2024年6月8日。
- [8]丹尼·古德温。2011年。谷歌搜索结果首位获得36.4%的点击量[研究]。https://www.searchenginewatch.com/2011/04/21/top-google-result-gets-36-4-of-clicks-study/ [8]丹尼·古德温。2011年。谷歌搜索结果首位获得36.4%的点击量[研究]。https://www.searchenginewatch.com/2011/04/21/top-google-result-gets-36-4-of-clicks-study/
- [9] Kelvin Guu, Kenton Lee, Zora Tung, Panupong Pasupat和Ming-Wei Chang。2020年, 《增强检索语言模型预训练》。ArXiv abs/2002.08909 (2020)。https://api.semanticscholar.org/CorpusID: 211204736
- [10]李子微、李娜妍、丽塔·弗里斯克、余铁正、苏丹、徐燕、石井惠子、边叶珍、安德烈·马多托和马帕斯卡。2023年。自然语言生成中的幻觉现象综述。《计算机调查》第55卷第12期(2023), 1-38页。
- [11]奥农·库马尔与希马宾杜·拉克鲁。2024年。通过操控大型语言模型提升产品曝光度。arXiv: 2404.07981[计算机信息检索]
- [12]R·阿尼尔·库马尔、扎伊杜丁·谢克和穆罕默德·福尔坎。2019年。搜索引擎优化技术综述。国际P2P网络趋势与技术期刊(2019)。https://doi.org/10.14445/22492615/IJPTT-V9I1P402
- [13]汤姆·科维亚特科夫斯基、珍妮·玛丽亚·帕洛马基、奥利维亚·雷德菲尔德、迈克尔·柯林斯、安库尔·P·帕里克、克里斯·阿尔贝蒂、丹妮尔·爱泼斯坦、伊利亚·波洛苏金、雅各布·德夫林、肯顿·李、克里斯蒂娜·图塔诺娃、利昂·琼斯、马修·凯尔西、张明伟、戴安德鲁·M、雅各布·乌斯科雷特、黎国伟和斯拉夫·彼得罗夫。2019年。《自然问题: 问答研究基准》。计算语言学协会会刊第7卷(2019), 453-466页。https://api.semanticscholar.org/CorpusID: 86611921
- [14] Nelson F.刘, 张天一与梁柏瑞。2023年。《生成式搜索引擎中的可验证性评估》。ArXiv abs/2304.09848(2023)。https://api.semanticscholar.org/CorpusID: 258212854
- [15]杨柳、丹·伊特、徐义冲、王硕、许如晨和朱晨光。2023年, 《G-Eval: 基于GPT-4的NLG评估与改进的人类对齐方法》。ArXiv abs/2303.16634 (2023)。https://api.semanticscholar.org/CorpusID: 257804696
- [16] G·D·马扬。2023年。谷歌SGE将如何影响您的流量——以及三个SGE恢复案例研究。搜索引擎领域(2023年9月5日)。https://searchengineland.com/how-google-sge-will-impact-your-traffic-and-3-sge-recovery-case-studies-431430 [16] G·D·马扬。2023年。谷歌SGE将如何影响您的流量——以及三个SGE恢复案例研究。搜索引擎领域(2023年9月5日)。https://searchengineland.com/how-google-sge-will-impact-your-traffic-and-3-sge-recovery-case-studies-431430 [16] G·D·马扬。2023年。谷歌SGE将如何影响您的流量——以及三个SGE恢复案例研究。搜索引擎领域(2023年9月5日)。https://searchengineland.com/how-google-sge-will-impact-your-traffic-and-3-sge-recovery-case-studies-431430
- [17]雅各布·梅尼克、玛雅·特雷巴茨、弗拉基米尔·米库利克、约翰·阿斯兰尼德斯、弗朗西斯·宋、马丁·查德威克、米娅·格莱斯、苏珊娜·杨、露西·坎贝尔·吉灵汉姆、杰弗里·欧文和内森·麦卡利斯。2022年。《训练语言模型以支持使用验证引用的答

- 案》。ArXiv abs/2203.11147 (2022)。https://api.semanticscholar.org/CorpusID: 247594830
- [18]格雷戈瓦·米亚隆、罗伯特·德西、玛丽亚·洛梅利、克里斯托弗·罗斯·纳尔姆潘蒂斯、拉马坎特·帕苏努鲁、罗伯特·雷亚努、巴普蒂斯·罗齐埃、蒂莫·希克、简·德维迪·尤、阿斯利·切利基尔马兹、爱德华·格拉夫、扬·勒昆和托马斯·西亚洛姆。2023。增强语言模型: 综述。ArXiv abs/2302.07842 (2023)。https://api.semanticscholar.org/CorpusID: 256868474
- [19]中野雷一郎、雅各布·希尔顿、S·阿伦·巴拉吉、吴杰夫、欧阳龙、克里斯蒂娜·金、克里斯托弗·赫塞、山塔努·贾恩、维内特·科萨拉朱、威廉·桑德斯、徐江、卡尔·科贝、泰娜·埃隆杜、格雷琴·克鲁格、凯文·巴顿、马修·奈特、本杰明·切斯和约翰·舒尔曼。2021年。WebGPT: 基于浏览器的人工智能问答系统(含人类反馈机制)。ArXiv abs/2112.09332 (2021)。https://api.semanticscholar.org/CorpusID: 245329531
- [20] OpenAI. 2022. 介绍ChatGPT。https://openai.com/index/chatgpt/
- [21] OpenAI、乔希·阿奇亚姆、史蒂文·阿德勒、桑迪尼·阿加瓦尔、拉玛·艾哈迈德、伊尔格·阿卡亚、弗洛伦西亚·莱奥尼·阿莱曼、迪奥戈·阿尔梅达、扬科·阿尔滕施密特、萨姆·阿尔特曼、希亚马尔·阿纳德卡特、雷德·阿维拉、伊戈尔·巴什金、苏希尔·巴拉吉、瓦莱丽·巴尔科姆、保罗·巴尔泰斯库、鲍海明、穆罕默德·巴瓦里安、杰夫·贝尔古姆、欧文·贝洛、杰克·伯丁、加布里埃尔·伯纳德特·夏皮罗、克里斯托弗·伯纳、伦尼·博格多诺夫、奥列格·博伊科、玛德琳·博伊德、安娜·路易莎·布拉克曼、格雷格·布罗克曼、蒂姆·布鲁克斯

迈尔斯·布伦达奇、凯文·巴顿、崔维·蔡、罗西·坎贝尔、安德鲁·坎恩、布里特妮·凯瑞、切尔西·卡尔森、罗里·卡迈克尔、陈柏蕊、张驰、福蒂斯·钱齐斯、陈德瑞、陈苏利、陈露琪、陈杰森、马克·陈、本·切斯、切斯特·乔、朱凯、郑亨元、戴夫·卡明斯、杰里米亚·柯里尔、戴云星、科里·德卡雷奥、托马斯·德格里、诺亚·多伊奇、达米安·德维尔、阿尔卡·达尔、大卫·多汉、史蒂夫·道林、希拉·邓宁、阿德里安·埃科菲特、阿蒂·埃莱蒂、蒂娜·埃隆杜、大卫·法尔希、利亚姆·费杜斯、尼科·费利克斯、西蒙·波萨达·费什曼、贾斯汀·福特、伊莎贝拉·富尔福德、高磊、埃利·乔治斯、克里斯蒂安·吉布森、维克·戈埃尔、塔伦·戈吉内尼、加布里埃尔·戈、拉法·贡蒂霍·洛佩斯、乔纳森·戈登、摩根·格拉夫斯坦、斯科特·格雷、瑞安·格林、约书亚·格罗斯、徐世祥、郭玉菲、克里斯·哈利西、杰西·韩、杰夫·哈里斯、何玉辰、迈克·希顿、约翰内斯·海德克、克里斯·赫塞、艾伦·希基、韦德·希基、彼得·霍舍尔、布兰登·霍顿、许健、胡胜利、胡欣、朱斯特·胡伊津加、沙坦努·贾恩、肖恩·贾恩、乔安妮·姜、安吉拉·姜、罗杰·姜、金浩俊、丹尼·金、金宗旭、金永植、扬·亨德里克·基希纳、杰米·基罗斯、马特·奈特、丹尼尔·科科塔约、Łukasz·康德拉丘克、安德鲁·康德拉奇、阿里斯·康斯坦丁尼迪斯、凯尔·科西奇、格雷琴·克鲁格、郭维沙、迈克尔·兰佩、伊凯·兰、泰迪·李、简·莱克、杰德·梁、丹尼尔·列维、李查明、肯尼·许瑞秋·林、莫莉·林、斯蒂芬妮·林、马特乌什·利特温、特蕾莎·洛佩兹、瑞安·洛、帕特里夏·吕、安娜·马坎朱、金·马尔法西尼、萨姆·曼宁、托多尔·马尔科夫、亚尼夫·马尔科夫斯基、比安卡·马丁、凯蒂·梅耶、安德鲁·梅恩、鲍勃·麦格鲁、斯科特·梅耶·麦金尼、克里斯汀·麦克莱维、保罗·麦克米伦、杰克·麦克尼耳、大卫·梅迪纳、阿洛克·梅塔、雅各布·梅尼克、卢克·梅茨、安德烈·米申科、帕梅拉·米什金、文尼·莫纳科、埃文·莫里卡瓦、丹尼尔·莫辛辛、董木、米拉·穆拉蒂、奥列格·穆尔克、大卫·梅利、阿什文·奈尔、中野雷一郎、拉吉夫·纳亚克、阿尔温德·尼拉坎坦、理查德·吴、诺贤宇、欧阳龙、卡伦·奥基夫、雅库布·帕乔基、亚历克斯·帕伊诺、乔·帕勒莫、阿什利·潘图利亚诺、詹巴蒂斯塔·帕拉斯卡诺·多洛、乔尔·帕里什、埃米·帕尔帕里塔、亚历克斯·帕索斯、米哈伊尔·帕夫洛夫、安德鲁·彭、亚当·佩雷尔曼、菲利普·德阿维拉·贝尔布特·佩雷斯、迈克尔·彼得罗夫、亨里克·蓬德·德奥利维拉·平托、迈克尔·波科尼、米歇尔·波克拉丝、维奇尔·H。庞、托利·鲍威尔、阿莱西娅·鲍尔、鲍里斯·鲍尔、伊丽莎白·普罗埃爾、劳尔·普里、亚历克·拉德福德、杰克·雷、阿迪提亚·拉梅什、卡梅伦·雷蒙德、弗朗西斯·瑞尔、肯德拉·林巴赫、卡尔·罗斯、鲍勃·罗特斯特德、亨利·鲁塞、尼克·赖德、马里奥·萨尔塔雷利、泰德·桑德斯、希巴尼·桑图尔卡、吉里什·萨斯特里、希瑟·施密特、大卫·施努尔、约翰·舒尔曼、丹尼尔·塞尔萨姆、凯拉·谢泼德、托基·舍尔巴科夫、杰西卡·谢、莎拉·肖克、普拉纳夫·夏姆、西蒙·西多尔、埃里克·西格勒、麦迪·西门斯、乔丹·西特金、卡塔琳娜·斯拉马、伊恩·索尔、本杰明·索科洛夫斯基、杨松、娜塔莉·施陶达赫、费利佩·彼得罗斯基·苏赫、娜塔莉·萨默斯、伊利亚·苏茨克韦尔、唐杰、尼古拉斯·泰扎克、玛德琳·B·汤普森、菲尔·蒂莱特、阿明·图通奇安、伊丽莎·白曾、普雷斯顿·塔格尔、尼克·特利、杰里·特沃雷克、胡安·费利佩·塞隆·乌里韦、安德烈娅·瓦洛内、阿伦·维贾维吉亚、切尔西·沃斯、卡罗尔·温赖特、贾斯汀·王杰、阿尔文·王、本·王、乔纳森·沃德、杰森·魏、CJ·温曼、阿基拉·韦利欣达、彼得·韦林德、王佳怡、李莲、马特·维特霍夫、戴夫·威尔纳、克莱门斯·温特、塞缪尔·沃尔里奇、黄汉娜、劳伦·沃克曼、谢尔温·吴、杰夫·吴、迈克尔·吴、萧凯、徐涛、莎拉·俞、Kevin Yu、袁启明、沃伊切赫·扎伦巴、罗文·泽勒斯、张乔、张马文、赵胜佳、郑天浩、庄俊堂、威廉·朱克、巴雷特·佐普。2024年。GPT-4技术报告。arXiv: 2303.08774 [cs.CL]

[22] A·沙扎德、德登·维塔爾沙·雅各布、納茲里·M·納維、海魯爾尼扎姆·賓·馬赫丁和馬爾赫尼·埃卡·薩普特里。2020年。搜索引擎优化的新趋势、工具与技术。《印度尼西亚电气工程与计算机科学杂志》第18卷（2020年），第1568页。https://api.semanticscholar.org/CorpusID: 213123106

[23] 克尔特·舒斯特、徐静、莫贾巴·科梅利、达朱、埃里克·迈克·史密斯、斯蒂芬·罗勒、梅根·昂、莫雅·陈、库沙尔·阿罗拉、约书亚·莱恩、莫尔特扎·贝鲁兹、W.K.F.安、斯宾塞·波夫、纳曼·戈亚尔、亚瑟·斯拉姆、布雷欧·伊兰、梅兰妮·坎巴杜尔和杰森·韦斯顿。2022年。《BlenderBot 3: 持续学习的对话式智能体——负责任交互实践》。ArXiv abs/2208.03188（2022）。https://api.semanticscholar.org/CorpusID: 251371589

[24] 罗马尔·托皮兰、丹尼尔·德弗雷塔斯、杰米·霍尔、诺姆·沙泽尔、阿普尔·库什雷斯塔、程恒哲、艾丽西亚·金、泰勒·博斯、莱斯利·贝克、杜宇、李亚光、李洪来、郑怀修、阿明·加福里、马塞洛·梅内加利、黄燕萍、马克西姆·克里昆、德米特里·列皮欣、秦杰、陈德浩、徐元忠、陈志峰、亚当·罗伯茨、马尔滕·博斯马、赵文森、周艳琪、张中清、伊戈尔·克里沃孔、威拉·拉什、马克·皮克特、普拉内什·斯里尼瓦桑、拉伊切·曼、凯瑟琳·迈尔·赫尔斯滕、梅雷迪思·林格·莫里斯、图尔西·多西、雷内利托·德洛桑托斯、托朱·杜克、约翰·索拉克、本·泽文·伯根、维诺德·库马尔·普拉巴卡兰、马克·迪亚兹、本·哈钦森、克

里斯汀·奥尔森、阿莱杭德拉·莫利纳、艾琳·霍夫曼·约翰、乔什·李、洛拉·阿罗约、拉维·拉贾库马尔、阿莲娜·布特里纳、马修·拉姆、维克托里娅·库兹米娜、乔·芬顿、亚伦·科恩、蕾切尔·伯恩斯坦、雷·库兹韦尔、布莱斯·阿吉拉·阿尔卡斯、克莱尔·崔、玛丽安·克洛克、埃德奇·郭尔。2022年。LaMDA: 对话应用语言模型。arXiv: 2201.08239 [cs.CL]

[25] 周春亭、刘鹏飞、徐普欣、斯里尼·艾尔、孙娇、毛玉宁、马雪哲、阿维亚·埃弗拉特、余平、L·余、张素珊、加尔吉·戈什、迈克·刘易斯、卢克·泽特洛梅耶和奥默·列维。2023年。LIMA: 少即是多的对齐方法。ArXiv abs/2305.11206（2023）。https://api.semanticscholar.org/CorpusID: 258822910

清单1：用于生成引擎的提示。GE将查询和5个来源作为输入，并输出基于来源的查询响应。

1	为给定的用户问题编写准确且简明的答案， 仅使用提供的汇总网页搜索结果。 答案应当正确、高质量，并由专家以公正且新闻报道式的语气撰写。 用户可选择语言包括英语、法语、西班牙语等。 应使用德语。答案应该是 信息丰富、有趣且引人入胜。答案的逻辑和推理应当严谨且具有可辩护性。每个 答案中的句子应立即后跟对搜索结果的内嵌引用。所引用的内容搜索结果应完全支持_所有_信息 在句子中。引用搜索结果时需使用[index]。当引用多个搜索结果时，应采用[1][2][3]格式而非[1,2,3]。您可以利用多个搜索结果进行全面回应，同时避免 不相关的检索结果。
2	
3	问题：{query}
4	
5	搜索结果：
6	{source_text}

一种对话式生成引擎

在第2.1节中，我们讨论了单轮生成式引擎——这种引擎仅根据用户查询输出单一响应。但新一代生成式引擎的一大优势在于其具备与用户进行主动双向对话的能力。通过这种对话机制，用户不仅能对查询或生成式引擎的回应进行澄清，还能提出后续问题。具体来说，在公式1中，输入内容已从单一查询qu转变为建模为对话历史H = (q, rt) 对。响应rt+1定义为：

GE := fLE (H, PU) → rt+1 (5)

其中t是转弯次数。

此外，为了促进用户互动，独立的LLM（语言模型）、Lf（跟随器）或L resp（响应器）会根据历史对话、用户偏好和rt+1指标生成建议的后续提问。这类智能设计旨在最大化用户参与度，既能让生成式引擎服务商通过提升用户互动率获益，也能帮助网站运营者增强品牌曝光度。更重要的是，这些智能提问能为用户提供更精准的细节信息支持。

B实验装置

B.1评估生成引擎

所使用的精确提示如清单1所示。

B.2基准

GEO基准库包含来自九个数据集的查询语句。各数据集的代表性查询语句如图2所示。此外，我们根据7个不同类别对每个查询语句进行标注。在标注过程中，我们使用GPT-4模型，并通过人工验证确保召回率和精确度达到高标准。但由于采用自动化系统，标注结果可能存在噪声干扰，因此需要谨慎对待。以下是各查询语句的具体说明：

列表2：GEO-bench中9个数据集的代表性查询

1	ORCAS
2	——全球化意味着什么
3	葡萄酒搭配清单4
5	### AllSouls 开放获取期刊是学术出版的未来吗？
7	-在英国，非西方哲学的研究是否应成为哲学学位的必要条件？
8	
9	达芬奇辩论
10	-所有公民都应该获得基本收入吗？
11	-政府应该提倡无神论吗？
12	
13	### ELIS
14	-为什么我的猫在玩玩具时踢它？
	咖啡因对肌肉有什么实际作用，特别是在锻炼方面？
16	
17	### GPT-4
18	-酮症饮食的好处是什么？
19	-文艺复兴时期对现代社会产生了哪些最深远的影响？
20	
21	###利马
22	-影响消费者行为的主要因素有哪些？
23	——谋杀悬疑小说有什么绝妙的转折呢？我想要的是有创意的情节，而不是重复老套的套路。
24	
25	###MS宏
26	-什么是一夫一妻制
27	2x岁儿童的正常bmi范围是多少
29	###自然问题
30	-短语bee line从何而来
31	-圣经中波斯的王子是谁32
33	### Perplexity.ai
34	-如何在LinkedIn上获得更多关注者
35	-为什么饭后血糖升高

- 难度级别：查询的复杂程度，从简单到复杂。
- 查询的性质：查询所寻求的信息类型，例如事实、意见或比较。
- 类型：查询的类别或领域，例如艺术和娱乐、金融或科学。
- 具体主题：查询的具体主题内容，例如物理、经济学或计算机科学。
- 敏感性：查询是否涉及敏感主题。
- 用户意图：用户查询背后的目的，例如搜索、购买或娱乐。
- 答案类型：查询所寻求的答案的格式，例如事实、意见或列表。

B.3评估指标

我们使用了7种不同的主观印象指标，其提示信息展示在我们的公开repository：https://github.com/GEO-优化/GEO中。

B.4地质勘测方法

我们提出了9种不同的生成引擎优化方法，用于优化网站内容以适应生成引擎。我们在完整的GEO基准测试集上评估了这些方法。此外，为了进一步验证这些方法的有效性，我们还进行了深入的研究。

方法	位置校正Word计数			主观印象								平均值
	Word总体位置			宗教。	不包括。	独特分部，后续行动			便壶	计数		
没有生成引擎优化的性能												
未优化	19.7(±0.7)	19.6(±0.5)	19.8(±0.6)	19.8(±0.9)	19.8(±1.6)	19.8(±0.6)	19.8(±1.1)	19.8(±1.0)	19.8(±1.0)	19.8(±0.9)	19.8(±0.9)	19.8(±0.9)
				1.6)	19.8(±0.6)	19.8(±1.1)	19.8(±1.0)	19.8(±1.0)	19.8(±0.9)	19.8(±0.9)	19.8(±0.9)	19.8(±1.6)
				19.8(±1.1)	19.8(±1.0)	19.8(±1.0)	19.8(±0.9)	19.8(±0.9)				19.8(±0.6)
非性能生成式引擎优化方法												
关键字堆砌独特词汇	19.6(±0.5)	19.5(±0.6)	19.8(±0.5)	20.8(±0.8)	19.8(±1.0)	20.4(±0.5)	20.6(±0.9)	19.9(±0.9)	21.1(±1.0)	21.0(±0.9)	20.6(±0.7)	
	20.6(±0.6)	20.5(±0.7)	20.7(±0.5)	20.8(±0.7)	20.3(±1.3)	20.5(±0.3)	20.9(±0.3)	20.4(±0.7)	21.5(±0.6)	21.2(±0.4)	20.9(±0.4)	
高性能生成引擎优化方法												
易于理解	21.5(±0.7)	22.0(±0.8)	21.5(±0.6)	21.0(±1.1)	21.1(±1.8)	21.2(±0.9)	20.9(±1.1)	20.6(±1.0)	21.9(±1.1)	21.4(±0.9)	21.3(±1.0)	
权威性	21.3(±0.7)	21.2(±0.9)	21.1(±0.8)	22.3(±0.8)	22.9(±0.8)	22.1(±0.9)	23.2(±0.7)	21.9(±0.4)	23.9(±1.2)	23.0(±1.1)	23.1(±0.7)	
技术术语	22.5(±0.6)	22.4(±0.6)	22.5(±0.6)	21.2(±0.7)	21.8(±0.8)	20.5(±0.5)	21.1(±0.6)	20.5(±0.6)	22.1(±0.6)	21.2(±0.2)	21.4(±0.4)	
流利度优化	24.4(±0.8)	24.4(±0.6)	24.4(±0.8)	21.3(±0.9)	23.2(±1.5)	21.2(±1.0)	21.4(±1.4)	20.8(±1.3)	23.2(±1.8)	21.5(±1.3)	22.1(±1.2)	
引证来源	25.5(±0.7)	25.3(±0.6)	25.3(±0.6)	22.8(±0.9)	24.2(±0.7)	21.7(±0.3)	22.3(±0.8)	21.3(±0.9)	23.5(±0.4)	21.7(±0.6)	22.9(±0.5)	
报价增加	27.5(±0.8)	27.6(±0.8)	27.1(±0.6)	24.4(±1.0)	26.7(±1.1)	24.6(±0.7)	24.9(±0.9)	23.2(±0.9)	26.4(±1.0)	24.1(±1.2)	25.5(±0.9)	
统计学补充	25.8(±1.2)	26.0(±0.8)	25.5(±1.2)	23.1(±1.4)	26.1(±0.9)	23.6(±0.9)	24.5(±1.2)	22.4(±1.2)	26.1(±1.2)	23.8(±1.2)	24.8(±1.1)	

表6：GEO基准测试中GEO方法的绝对印象指标对比。与基线方法相比，传统SEO常用的关键词堆砌等基础方法表现欠佳。但本研究提出的统计学加权 and 引文加权等创新方法，在各项指标上均展现出显著提升。其中最佳方案在位置调整Word计数和主观印象指标上分别较基线提升了41%和28%。

方法	位置调整Word计数主观印象							位置调整Word计数主观印象						
	Word位置总体相对影响独特分区后续位置数量平均值							Word位置总体相对影响独特分区后续位置数量平均值						
	Word位置总体相对影响独特分区后续位置数量平均值							Word位置总体相对影响独特分区后续位置数量平均值						
没有生成引擎优化的性能														
无优化	24.0	24.4	24.1	24.7	24.7	24.7	24.7	24.7	24.0	24.4	24.1	24.7	24.7	24.7
24.7	24.7	24.7												
非性能生成式引擎优化方法														
关键词堆砌					21.9	21.4	21.9	26.3	27.2	27.2	30.2	27.9	28.2	26.9
独特词汇					24.0	23.7	23.6	24.9	25.1	24.7	24.4	23.0	23.6	23.9
高性能生成引擎优化方法														
权威性					25.6	25.7	25.9	28.9	30.9	31.2	31.7	31.5	26.9	29.5
流利度优化					25.8	26.2	26.0	28.9	29.4	29.8	30.6	30.1	29.6	29.6
引证来源					26.6	26.9	26.8	19.8	20.7	19.5	18.9	20.0	18.5	18.9
报价增加					28.8	28.7	29.1	31.4	31.9	31.9	32.3	31.4	31.7	30.9
统计学补充					25.8	26.6	26.2	31.6	33.4	34.0	33.7	34.0	33.3	33.1
														33.9

表7：基于Perplexity.ai生成引擎的GEO基准测试中，GEO方法的性能提升表现。相较于SEO领域常用的关键词堆砌等基础方法，我们的创新方案在统计加权和引文添加等指标上均实现显著提升。其中表现最优的方法在位置调整Word计数指标上较基准提升22%，主观印象指标更是达到37%的亮眼成绩。

为了减少结果的差异，我们在五个不同的随机种子上运行实验，并报告平均值。

B.5 GEO方法的提示

我们所有的实验提示都发布在公共代码库中：<https://github.com/GEO-optim/GEO>。所有实验均使用GPT-3.5 turbo进行。

C结果

我们在5个随机种子上进行实验, 并在表6中给出了带有统计偏差的结果

C.1野外GEO：部署生成引擎的实验

我们还在实际部署的生成引擎Perplexity.ai上评估了提出的生成引擎优化方法。由于该平台不支持用户指定源URL, 我们改为通过文件上传方式提供源文本, 并确保所有答案仅基于提供的文件内容生成。所有方法均在测试集的200个样本子集中进行评估, 使用Perplexity.ai的结果详见表7。